

LU3I026 - Science des données

Des données à l'apprentissage

Olivier Schwander <olivier.schwander@sorbonne-universite.fr>

Sorbonne Université

2024-2025

Formaliser le problème d'IA

Discussion informelle

- ▶ «On veut de l'IA»
- ▶ «sur nos données»
- ▶ «pour faire ci ou ça»
- ▶ «avec telle et telle contraintes»


Objectif

- ▶ Traduction dans un vocabulaire IA
- ▶ Correspondance avec les concepts scientifiques

Première question à poser

- ▶ «Cher.e chef.fe , avez-vous des données ?»
- ▶ Parfois, la réponse est non...
- ▶ Or c'est un besoin capital !

Différentes données: images




Différents données: texte

Extrait de wikipedia

ChatGPT est un [prototype](#) d'[agent conversationnel](#) utilisant l'[intelligence artificielle](#), développé par [OpenAI](#), et spécialisé dans le dialogue. L'agent conversationnel est un [modèle de langage](#) affiné par [apprentissage supervisé](#) et par [apprentissage par renforcement](#).

Le sigle *ChatGPT* signifie « *Generative pre-trained transformer* » (« *Transformateur générique pré-entraîné* »).

Différentes données: séries temporelles



Différentes données: autres

Graphes

- ▶ Réseaux sociaux
- ▶ Échanges téléphoniques, sms
- ▶ Co-auteurs de publications scientifiques

Vidéos

- ▶ Image + aspect temporel

Conversations

- ▶ Échanges de type question-réponse (ChatGPT)

Différents domaines: texte médical

Centres d'Imagerie Médicale

Imagerie Médicale - Centre d'Imagerie Médicale Centre d'Imagerie Médicale - Centre d'Imagerie Médicale Centre d'Imagerie Médicale - Centre d'Imagerie Médicale			
Radiologie Diagnostique et Interventionnelle Radiologie Diagnostique et Interventionnelle Radiologie Diagnostique et Interventionnelle			
Mammographie - Radiologie Diagnostique Mammographie - Radiologie Diagnostique Mammographie - Radiologie Diagnostique			
Echographie - Radiologie Diagnostique Echographie - Radiologie Diagnostique Echographie - Radiologie Diagnostique			
IRM - Radiologie Diagnostique IRM - Radiologie Diagnostique IRM - Radiologie Diagnostique			
TDM - Radiologie Diagnostique TDM - Radiologie Diagnostique TDM - Radiologie Diagnostique			
Angiographie - Radiologie Diagnostique Angiographie - Radiologie Diagnostique Angiographie - Radiologie Diagnostique			
Radiologie Nucléaire - Radiologie Diagnostique Radiologie Nucléaire - Radiologie Diagnostique Radiologie Nucléaire - Radiologie Diagnostique			

Dr. Jean-Marie BIAIXAS
Radiologue en radiologie de la femme et
de l'enfant
Certificat d'expertise en radiologie de la femme
(2015-2020)

Mme HENRY Vassiliki
Chirurgienne - 0100000000
Dr. Jean-Marie BIAIXAS
Dr. Jean-Marie BIAIXAS

ECHOCARTE MAMMAIRE BIATERALE -
Examen réalisé par échographe TOSHIBA APLORIX (à la suite de la prise en charge de la tumeur)

Mamographie -
Niveau de qualité de l'examen satisfaisant.


Résumé
L'examen échographique montre un nodule hypéchogène polylobé d'aspect tumoral non lipidique, mesurant 2,5 x 1,5 x 1,5 cm. Ce nodule est peu élastique, sans écoulement vasculaire visible au Doppler couleur.
L'ensemble du sein est de qualité satisfaisante, présence d'une formation microkystique du quadrant supérieur externe.
Il n'y a pas de vascularisation dans le nodule nodulaire décrit.
Le sein gauche est d'aspect normal sans lésion focale.

Compte tenu de l'aspect échographique et du caractère microkystique à été noté - il est en évidence dans la région supérieure externe droite une petite nodularité, dense de caractère kystique, contenant quelques microcalcifications.
De l'autre côté, une nodularité est observée au sein de la glande.
A gauche, le sein est tout à fait homogène, pas de nodule ou de microcalcifications.


La conclusion
Niveau de confiance satisfaisant, sans lésion du quadrant supérieur externe du sein droit, classé 4C.
A surveiller en prévision kystique.
à CR 1 à gauche.

Dr. Jean-Marie BIAIXAS
Le présent document est destiné à l'usage personnel du patient et ne doit pas être communiqué à d'autres personnes.
Le présent document est destiné à l'usage personnel du patient et ne doit pas être communiqué à d'autres personnes.
Le présent document est destiné à l'usage personnel du patient et ne doit pas être communiqué à d'autres personnes.

Différents domaines: image médicale




Différents domaines: écriture manuscrite



Différentes domaines: images satellites



Différentes domaines: audio



Différents domaines

Voiture autonome: vision

- ▶ Été – hiver
- ▶ Ville – campagne
- ▶ Amérique du nord – Europe

Contrôle

- ▶ Voiture autonome – drone – autre robot

Tâches de machine learning

Choix à faire

- ▶ Formalisation
- ▶ Définir les objectifs
- ▶ Définir le protocole expérimental

Exemple

- ▶ *Classification*
- ▶ *binaire*
- ▶ évaluation avec *accuracy*
- ▶ *découpage train/test* fixé de telle façon

Données

Matériau de base

- ▶ **Incourtournable**
- ▶ (sauf cas particulier)
- ▶ Vérifier: quantité, qualité

Avant de se lancer avec une méthode IA

- ▶ Charger les données
- ▶ Compréhension minimale
- ▶ Statistiques simples, visualisations
- ▶ Réfléchir aux prétraitements

Sources de données

Monde académique


- ▶ Données jouets
- ▶ Données réelles
- ▶ Souvent bien connu et maîtrisés: stockage propre, exemples d'utilisation, bibliothèques

Monde réel

- ▶ Base de données
- ▶ Fichiers structurés: CSV, JSON, YAML, tableurs, autres formats
- ▶ Web: services web, API, scrapping

Exemple du CSV

Google		Google		Google		Google		Google		Google	
Actions	Insert	Format	Tools	Window	Help	Tools	Help	Tools	Help	Tools	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format	Tools	Window	Help	File	Edit	Format	Tools	Window	Help
File	Edit	Format									



```
1 "Region","total_population","percent_white","percent_black","percent_asian","percent_hispanic","per_capita_income","me
2 "alabama",4709277,67.26,1.4,23680,501.38,1
3 "alaska",726526,63.3,0.6,12651,978.33,1
4 "arizona",6479083,57.4,3.3,38,25338,747.36,1
5 "arkansas",2933369,74.15,1.7,22178,488.37,5
6 "california",3765381,40.6,13.38,25527,1119.25,4
7 "colorado",5119329,78.4,3.21,31189,825.36,1
8 "connecticut",3583581,78.5,4.18,37882,488.48,2
9 "delaware",988466,65.21,13.8,21819,608.38,5
10 "district of columbia",619375,35.49,3.18,45298,1154.33,8
11 "florida",19891356,77.15,2.23,26236,838.41,1
12 "georgia",9801817,55.38,3.9,25182,673.35,6
13 "hawaii",1376298,23.2,37.9,29385,1228.38,3
14 "idaho",1583366,84.1,1.1,22260,887.34,9
15 "illinois",12408554,63.14,5.16,26666,759.36,8
16 "indiana",6514981,81.9,2.6,24635,577.37,1
17 "iowa",3462553,88.3,2.3,27827,534.38,1
18 "kansas",2868187,78.6,2.1,26929,551.36,1
19 "kentucky",4361333,86.6,1.3,23462,506.38,2
20 "louisiana",4597868,68.32,4.4,24442,458.36,1
21 "maine",1328328,94.1,1.1,28824,664.43,2
22 "maryland",5834799,58.29,6.38,30354,484.38,1
23 "massachusetts",6860869,76.6,1.8,25763,896.39,2
24 "midwest",9888895,76.14,3.5,25881,823.39,1
25 "missouri",5947746,83.5,5.5,30913,754.37,6
26 "mississippi",2978672,58.37,1.3,28018,518.36,2
27 "missouri",6887182,81.11,2.4,25449,549.38,1
28 "montana",1055547,87.4,1.5,25273,577.39,9
29 "nebraska",1841825,82.4,2.9,26899,563.36,3
30 "nevada",2789665,53.8,7.7,26589,848.36,6
31 "new hampshire",1312171,90.2,2.1,33134,878.41,5
32 "new jersey",8852488,59.19,3.18,36827,1824.39,1
33 "new mexico",2067886,48.2,1.47,23763,635.36,7
34 "new york",19457853,58.14,8.18,32382,953.38,1
```

Un fichier texte: des lignes

- Valeur1 VIRGULE Valeur2 VIRGULE etc
- Valeur1 VIRGULE Valeur2 VIRGULE etc

Quelques outils

Éviter Python pur

Pandas – Polars

- ▶ Réflexe à avoir: chargement, filtrage, statistiques, visualisation
- ▶ Point de vue base de données
- ▶ `read_csv` (et plein d'autres)

Numpy – Scipy

- ▶ Implémentations d'algorithmes
- ▶ Calcul scientifique
- ▶ `loadtxt`

Requests – HTTPX – BeautifulSoup – Playwright

- ▶ HTTP, HTML, Javascript

Regarder: fast-checking

- ▶ Dimensions des structures de données
- ▶ En-têtes des colonnes
- ▶ print tous simples

	region	total_population	percent_white	percent_black	percent_
0	alabama	4799277	67	26	
1	alaska	720316	63	3	
2	arizona	6479703	57	4	
3	arkansas	2933369	74	15	
4	california	37659181	40	6	

	percent_hispanic	per_capita_income	median_rent	median_age
0	4	23680	501	38.1
1	6	32651	978	33.6
2	30	25358	747	36.3
3	7	22170	480	37.5
4	38	29527	1119	35.4

Indicateurs statistiques

Outils mathématiques simples

- Moyennes, médianes, écart-types, percentiles

Outils informatique

Pandas describe (attention: pour vous ! pas pour un rapport propre !)

	Name	Team	Number	Position	Age	Height	Weight	College	Salary
count	364	364	364.000000	364	364	364	364.000000	364	3.640000e+02
unique	364	30	NaN	5	22	17	NaN	115	NaN
top	Cleanthony Early	New Orleans Pelicans	NaN	SG	24.0	6-9	NaN	Kentucky	NaN
freq	1	16	NaN	87	41	49	NaN	22	NaN
mean	NaN	NaN	16.829670	NaN	NaN	NaN	219.785714	NaN	4.620311e+06
std	NaN	NaN	14.994162	NaN	NaN	NaN	24.793099	NaN	5.119716e+06
min	NaN	NaN	0.000000	NaN	NaN	NaN	161.000000	NaN	5.572200e+04
20%	NaN	NaN	4.000000	NaN	NaN	NaN	195.000000	NaN	9.472760e+05
40%	NaN	NaN	9.000000	NaN	NaN	NaN	212.000000	NaN	1.638754e+06
50%	NaN	NaN	12.000000	NaN	NaN	NaN	220.000000	NaN	2.515440e+06









Visualisation

Graphiques

- Histogrammes, courbes, nuages de points, etc

Outils informatique

- Matplotlib, Bokeh, Seaborn, Altair



Autres types de données


Visualisation adaptée !

- ▶ Images: afficher des images
- ▶ Texte: le texte...
- ▶ Son: écouter
- ▶ etc

Oui mais: retour sur la qualité des données

Valeurs aberrantes (outliers)

Histogramme des prix au km des courses Blablacar



(bonus: dire du mal de cette figure)

Comment faire ?

- ▶ À la main: pas évident
- ▶ Automatiquement: difficile

Conclusion méthodologique

Contexte

- ▶ Apprentissage supervisé ou non
- ▶ Tâche de classification ou de régression

Modèles

- ▶ Linéaire
- ▶ k -Plus proches voisins

Prétraitements

- ▶ Données catégorielles
- ▶ Normalisation
- ▶ Transformation des données

Conclusion mathématique

Outils statistiques

- ▶ Moyennes, écart-type
- ▶ Distribution gaussienne
- ▶ Corrélation

Outils géométriques

- ▶ Droites, hyper-plans, surfaces
- ▶ Distances, produits scalaires

Conclusion informatique

Pandas

- ▶ Chargement des données
- ▶ Analyse préliminaire
- ▶ Statistique descriptive

Numpy

- ▶ Implémentation des algorithmes
- ▶ Bas-niveau
- ▶ Calcul matriciel **efficace**
- ▶ **JAMAIS** de boucle `for` de Python