

MAPSI — cours 6 :

Chaîne de Markov

Pierre-Henri Willemin & Raphaël Fournier-S'niehotta
(& Nicolas Thome)

LIP6 / ISIR – Sorbonne Université, France

- Les problèmes traités jusqu'ici :

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ \vdots & & & \\ x_{N1} & x_{N2} & \cdots & x_{Nd} \end{bmatrix}, \text{ et parfois : } Y = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}$$


- Chaque individu $\mathbf{x} = [x_1, x_2, \dots, x_d]$ est un vecteur **i.i.d.**
- **Les séquences** ne rentrent pas dans ce cadre

Tâches :

- Classification / Clustering
- Etiquetage / Segmentation
- Reconnaisance de chaîne de caractères
- Génération de séquences
- Modélisation de la diffusion



- Reconnaisance de paroles




Problème

- Méthodes standards de classification/clustering $\Rightarrow$ **transition difficile** vers les **données de taille variable**
- $\Rightarrow$ **modèles génératifs de séquences** (de taille variable)

Approche vectorielle : $X = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1d} \\ \vdots & & & \\ X_{N1} & X_{N2} & \cdots & X_{Nd} \end{bmatrix}$

Approche séquentielle :



Modèles génératifs

Pierre-Henri Willemin & Raphaël Fournier-S'niehotta
(& Nicolas Thome)

LIP6 / ISIR – Sorbonne Université, France

Rappel sur les modèles génératifs

- 1 Choix d'une modélisation des données : $p(\mathbf{x}|\theta)$
- 2 Apprentissage = trouver θ
- 3 Application possible : décision bayésienne

$$r(\mathbf{x}) = \arg \max_k p(\theta_k|\mathbf{x}) = \frac{p(\mathbf{x}|\theta_k)p(\theta_k)}{p(\mathbf{x})}$$

- 4 Application bis : génération de $\tilde{\mathbf{x}} \sim \mathcal{D}(\theta_k)$

Apprentissage d'un modèle génératif $\Leftrightarrow$ Estimation de densité

- Estimer θ_k = estimer une densité de probabilité d'une classe
- Hypothèse (forte) : les θ_k sont supposés indépendants
- Techniques d'estimation des θ_k

Maximum de vraisemblance (données vec.)

- $D = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ exemples supposés générés par $p(\mathbf{x}|\theta)$
- Adéquation entre les données et le modèle
 - Notion de vraisemblance des observations
 - Hyp : les données sont indépendantes

$$\mathcal{L}(D, \theta) = p(D|\theta) = \prod_{i=1}^N p(\mathbf{x}_i|\theta)$$

- Optimisation :

$$\theta^* = \arg \max_{\theta} (\mathcal{L}(D, \theta)) = \arg \max_{\theta} (\log \mathcal{L}(D, \theta))$$

- Résolution :

- Analytique : $\frac{\partial \mathcal{L}(D, \theta)}{\partial \theta} = 0$
- Approchée : EM, gradient...

- Modèle du jour = **modèle de Markov**
- Entrée = $\mathbf{x} = \{x_1, \dots, x_T\}$
 - Séquence d'observations, taille variable
 - Dépendance entre x_t et x_{t+1}
 - Hypothèse i.i.d. entre les $\mathbf{x}_i$
- Problématiques
 - Classification (supervisée)
 - Modèle $\lambda = \{\Pi, A\}$ [spécifique]
 - 1 modèle par classe [classique]
 - Vraisemblance : $\log \mathcal{L} = \sum_i \log (p(\mathbf{x}_i | \lambda))$ [classique]
 - Apprentissage : $\lambda^* = \text{Argmax}_{\lambda} \log \mathcal{L}$ [classique]
 - Inférence : $c^* = \text{Argmax}_c p(\mathbf{x}_i | \lambda_c^*)$ [classique]
 - Catégorisation (non-supervisée) [classique]
 - ... idem + bouclage EM
 - Décodage : traduction, reconnaissance d'écriture, décodage génome, ...
 - ... prochaine séance, modèle plus compliqué

- Outil pour faire de la prévision dans des **espaces discrets**
- Chaîne de Markov d'ordre k
 - Séquence de variables aléatoires $\mathbf{x} = (x_1, \dots, x_T)$ qui prend ses valeurs dans un ensemble fini d'états $Q = (q_1, \dots, q_N)$ et qui vérifie les propriétés dites de Markov :
 - **Chaîne de Markov d'ordre k** (horizon) :

$$p(x_{t+1} = q_j | x_1, \dots, x_t) = p(x_{t+1} = q_j | x_{t-k+1}, \dots, x_t)$$

- Dans la suite : chaînes d'ordre 1.
- Exemple : météo sur un an (soleil, nuage, pluie)
 - $Q = [So, Nu, Pl]$
 - $\mathbf{x} = [x_1 = Nu, x_2 = So, \dots, x_{365} = Pl]$

Soit un exemple très simple :

- $Q = [So, Nu, Pl]$

- $\mathbf{x} = [x_1 = Nu, x_2 = So, \dots, x_{365} = Pl]$

- Combien de paramètres pour une chaîne d'ordre 1 ?

9 (+3)

- Combien de paramètres pour une chaîne d'ordre 2 ?

27 (+3)


- Une chaîne de Markov d'ordre 1 est entièrement spécifiée par la donnée :

- d'une matrice de transition

$$\mathbf{A} = [a_{ij} = p(x_{t+1} = q_j | x_t = q_i)]$$

- et des probabilités initiales :

$$\Pi = [\pi_i = p(x_1 = q_i)]$$



- Probabilité d'une séquence

$$p(\mathbf{x}|\lambda) = p(x_1, \dots, x_T | \lambda)$$

Hypothèse markovienne d'ordre 1

Décomposition du calcul

$$\begin{aligned}p(\mathbf{x}|\lambda) &= p(x_1, \dots, x_T|\lambda) \\&= p(x_T|x_1, \dots, x_{T-1}, \lambda) \times p(x_1, \dots, x_{T-1}|\lambda) \\&= p(x_T|x_1, \dots, x_{T-1}, \lambda) \times p(x_{T-1}|x_1, \dots, x_{T-2}, \lambda) \dots \\&\quad \times p(x_1, \dots, x_{T-2}|\lambda) \\&= \prod_{t=2}^T p(x_t|x_1, \dots, x_{t-1}, \lambda)p(x_1|\lambda)\end{aligned}$$

Après hypothèse d'ordre 1 :

$$\begin{aligned}p(\mathbf{x}|\lambda) &= \prod_{t=2}^T p(x_t|x_1, \dots, x_{t-1}, \lambda)p(x_1|\lambda) = \prod_{t=2}^T p(x_t|x_{t-1}, \lambda)p(x_1|\lambda) \\&= \pi_{x_1} \prod_{t=2}^T a_{x_{t-1}, x_t}\end{aligned}$$

Représentation matricielle

- Matrice de transition **A** de taille $N \times N$
 - Lignes $\mathbf{x}_t$, colonnes $\mathbf{x}_{t+1}$
 - Matrice stochastique, chaque ligne somme à 1 : $\sum_{j=1}^N a_{ij} = 1$
- Matrice de transition **A** de taille $N \times N$
 - Lignes $\mathbf{x}_t$, colonnes $\mathbf{x}_{t+1}$
 - Matrice stochastique, chaque ligne somme à 1
- $\mathbf{p}_t := p(x_t = q_i | x_1, \dots, x_{t-1}, \lambda), \forall i \in \{1; N\}$
 - $\mathbf{p}_t$ vecteur ligne, taille $1 \times N$
- $\mathbf{p}_{t+1} := p(x_{t+1} = q_i | x_1, \dots, x_t, \lambda), \forall i \in \{1; N\}$
 - $\mathbf{p}_{t+1}$ vecteur ligne, taille $1 \times N$
- Matrice de transition **A** de taille $N \times N$
- $\mathbf{p}_t / \mathbf{p}_{t+1}$ vecteurs de probabilité à $t / t + 1$
- Treillis pour calculer le vecteur de probabilité $\mathbf{p}_{t+1} \forall j \in \{1; N\}$
 - $p(x_{t+1} = q_j) = \sum_{i=1}^N p(x_t = q_i) p(x_{t+1} = q_j | x_t = q_i) = \sum_{i=1}^N p(x_t = q_i) a_{ij}$

$$\mathbf{p}_{t+1} = \mathbf{p}_t \times \mathbf{A}$$




Il fait soleil... Quel temps fera-t-il dans N jours ? (distribution de probabilités)


- ① Je rentre sur la ligne *soleil*... $x_0 = S$
- ② A $t = 1$, $\{a_{x.}\}$ me donne la distribution des probabilités des états
 $p(x_1 = q_i) = a_{S,i} \Rightarrow \mathbf{p}_1 = \{a_{S,i}\}_{i \in \{1;N\}}$
- ③ Ensuite on itère :
 - $\mathbf{p}_2 = \mathbf{p}_1 \times \mathbf{A}$
 - $\mathbf{p}_N = \mathbf{p}_1 \times \mathbf{A}^{N-1}$

Représentation graphique

Automate basique :



Comment introduire la notion de commencement ?



Algorithm 1: Génération d'une séquence $\mathbf{x}$

Data: A, Π

Result: $\mathbf{x}$

$\mathbf{x} \leftarrow [];$

Tirer x_1 en fonction de Π ;

$x_t \leftarrow x_1, t \leftarrow 1;$

$\mathbf{x} \leftarrow [\mathbf{x}, x_{\text{courant}}];$

while x_t *n'est pas l'état final* **do**

$x_{t+1} \leftarrow \text{tirage selon } (A(x_t, :));$

$t \leftarrow t + 1;$

- Plusieurs variantes dans la clause du *while*
- Comment effectuer un tirage selon une loi de probabilité discrète ?

Outil pour le tirage aléatoire selon une loi discrète

Soit la loi :

A	1	2	3
$P(A)$	0.3	0.2	0.5

Comment effectuer un tirage selon $P(A)$?

- 1 Faire la somme cumulée de la loi

A	1	2	3
<i>cumsum</i>	0.3	0.5	1


- 2 Tirer un nombre x entre 0 et 1 selon la loi uniforme
- 3 Initialiser $vx = 1$
- 4 Tant que $cumsum[vx] < x$
 - $vx++$

Génération (sur un exemple)

- $q_1 = \text{Pluie}$, $q_2 = \text{Nuages}$, $q_3 = \text{Soleil}$

- $A =$

0.1	0.1	0.8
0.1	0.15	0.75
0.05	0.05	0.9



PSSSSSSSSSSSSNSSSSSSSSSSSSSSSSSSSSSSSS
SSSSSSSSSSSSSSPSSSSSSNPSSSSSPNSSSSSSNSS
SSSSPSSSSSSSSSSPSSSSSSSSSSSSSSPSSSSSSSS

- Quelle est la probabilité d'observer une séquence de soleil de longueur d ? [en se trouvant au premier jour de soleil]
- Quelle est la durée moyenne d'une séquence consécutive de soleil ?

Quelle est la probabilité d'observer une séquence de soleil de longueur d (étant donné que l'on se trouve au premier jour de soleil) ?

Loi géométrique

Notons la longueur de la sous-séquence de soleil D_S ,

$$P(D_S = d) = a_{ss}^{d-1}(1 - a_{ss})$$

Quelle est la longueur moyenne d'une séquence de soleil ?

Espérance de la loi géométrique

$$E[D_S] = \sum_{d=1}^{\infty} d a_{ss}^{d-1}(1 - a_{ss}) = \frac{1}{1 - a_{ss}}$$

Sketch of proof (voir TD) avec $k = d - 1$ et $p = 1 - a_{ss}$:

$$\begin{aligned} E(Y) &= \sum_{k=0}^{\infty} (1 - p)^k p \cdot (k + 1) \\ &= p \sum_{k=0}^{\infty} (1 - p)^k (k + 1) \end{aligned}$$

Stationnarité : CM converge-t-elle $\rightarrow$ mesure stationnaire μ ?

- **Point fixe**, proba des états ne change plus au cours du temps
 - μ = **pondération stationnaire** (inchangée après une transition)

$$\mu = \mu \mathbf{A}$$

- si $\forall i, \mu_i \geq 0, \sum_i \mu_i = 1$: μ est alors une **distribution stationnaire**
 - Distribution moyenne des états
- CM : paramètres $\lambda := (\mathbf{A}, \mathbf{\Pi})$
- **Existence** : conditions pour que la CM converge (ou pas)
- **Unicité** : point fixe unique (indépendant de $\mathbf{\Pi}$)

$$\mu = \mu \mathbf{A}$$

- Stationnarité : $\mu^T = \mathbf{A}^T \mu^T$
- **Condition nécessaire** : Solution donnée par le sous-espace propre (SEP) associé à la de valeur propre 1 de $\mathbf{A}^T$
 - 1 est valeur propre (VP) de $\mathbf{A}^T$ car 1 est VP de $\mathbf{A}$ ($\mathbf{A}^T$ et $\mathbf{A}$ ont même VPs). $\mathbf{A}$ est une matrice stochastique $\rightarrow (1, \dots, 1)$ vecteur propre associé à VP 1.
- **Condition suffisante ?**
 - ① SEP de dimension 1, et vecteur propre proba : solution unique
 - ② SEP de dimension >1 : solution non unique



Quel condition sur la CM pour que 1 soit vérifiée ?

Irréductibilité des CM


CM irréductible

- **CM irréductible** : chaque état est accessible à partir de chaque autre état.
- Graphe G de la CM fortement connexe, pas d'état final/absorbant
- **Chaîne réductible** : plusieurs composantes du graphe

CM irréductible



CM réductible




	1	3	4	5	2
1	0,5	0,5	0	0	0
3	0,4	0,6	0	0	0
4	0	0	0,1	0,9	0
5	0	0	0,5	0,5	0
2	0,25	0,25	0	0	0,5

Périodicité

- Période d'un état : PGCD des longueurs des cycles
 - Longueur cycle : temps n pour revenir dans un état, $P(X_n = i | X_0 = i) > 0$
- Période CM : PGCD de la période de tous ses états
 - Période $k > 1$: chaîne périodique
 - Période $k = 1$: chaîne apériodique
- Propriété : états de chaque composante CM ont même période


Périodicité des CM : exemples

CM irréductible apériodique



Etat 0 : PGCD(3,4)=1
 Etats 1-3 : PGCD(4,7)=1
 Etat 4-5 : PGCD(3,7)=1

CM irréductible périodique



Période = 2

Un processus ergodique est un processus stochastique pour lequel les statistiques peuvent être approchées par l'étude d'une seule réalisation suffisamment longue.

- Une chaîne de Markov est ergodique si π_n converge, indépendamment de π_0 .
- π_n converge alors vers π^* , la distribution stationnaire.
- L'espace propre associé à la VP 1 de $\mathbf{A}^T$ dimension 1


Théorème

Les chaînes **irréductible** et **apériodique** sont **ergodiques**

- Dans ce cas :
 $\mathbf{A}^\infty = (\mathbf{\Pi}_1, \dots, \mathbf{\Pi}_N)$, avec $\mathbf{\Pi}_k = (\Pi_k, \dots, \Pi_k) \in \mathbb{R}^N$
- et $\forall \mathbf{x}$ tq $\sum_{i=1}^N x_i = 1$, $\mathbf{x}\mathbf{A}^\infty = (\Pi_1, \dots, \Pi_N)$ (convergence vers $\mathbf{\Pi}$)

Convergence des CM : exemple 1


CM irréductible apériodique
 $\Rightarrow$ **ergodique**



Etat 0 : PGCD(3,4)=1
Etats 1-3 : PGCD(4,7)=1
Etat 4-5 : PGCD(3,7)=1

$\Rightarrow$ **Convergence**

CM irréductible périodique
 $\Rightarrow$ **non ergodique**





Période = 2
Sûr $\neq$ (2, 4, 6) pour n pair
Sûr $\neq$ (3, 5, 7) pour n impair

$\Rightarrow$ **Pas de convergence**

Convergence des CM : exemple 2


CM irréductible apériodique
 $\Rightarrow$ **ergodique**



1 VP de A^T

$\Rightarrow$ **Convergence**
indépendante de Π

CM réductible apériodique
 $\Rightarrow$ **non ergodique**



	1	3	4	5	2
1	0,5	0,5	0	0	0
3	0,4	0,6	0	0	0
4	0	0	0,1	0,9	0
5	0	0	0,5	0,5	0
2	0,25	0,25	0	0	0,5



2 VPs de A^T

$\Rightarrow$ **Convergence**
dépendante de Π

Exemples & discussion (1)

CM irréductible ? Apériodique ? Ergodique ?


Matrice de transition :



Exemples & discussion (2)

CM irréductible ? Apériodique ? Ergodique ?


Matrice de transition :




Exemples & discussion (3)

CM irréductible ? Apériodique ? Ergodique ?

Matrice de transition :




CM irréductible ? Apériodique ? Ergodique ?



	1	3	4	5	2
1	0,5	0,5	0	0	0
3	0,4	0,6	0	0	0
4	0	0	0,1	0,9	0
5	0	0	0,5	0,5	0
2	0,25	0,25	0	0	0,5

Matrice de transition :





Modélisation (2)

- Séquence de lancers de pièce(s)...

p_k : probabilité de faire *pile* avec la pièce k

p : probabilité de faire *pile*




Modélisation (3)

- Modélisation de parcours utilisateur sur un site web
 - Catégorisation / publicité personnalisée
 - Optimisation du site / pré-chargement de pages
- 1 trace = longueur variable...

Modèle

- **Etats :**
page du site
- **Transitions :**
hyperliens



Apprentissage des chaines de Markov

Pierre-Henri Willemin & Raphaël Fournier-S'niehotta
(& Nicolas Thome)

LIP6 / ISIR – Sorbonne Université, France

- Etant donnée une séquence d'états, calculer sa probabilité Vu précédemment :

$$\begin{aligned} p(X|\lambda) &= \prod_{t=2}^T p(x_t|x_1, \dots, x_{t-1}, \lambda) p(x_1|\lambda) = \prod_{t=2}^T p(x_t|x_{t-1}, \lambda) p(x_1|\lambda) \\ &= \pi_{x_1} \prod_{t=2}^T a_{x_{t-1}, x_t} \end{aligned}$$

- Comment apprendre une CM à partir d'exemples ?
- Comment faire de la classification de séquences avec des CM ?

- Soit une base de séquences $B = \{X^1, \dots, X^K\}$ (N états possibles)
- Critère de vraisemblance

$$\log \mathcal{L}(B, \lambda) = \log\left(\prod_{k=1}^K p(X^k|\lambda)\right) = \sum_k \log(p(X^k|\lambda))$$

- Optimisation :

$$\lambda^* = \arg \max_{\lambda} \log \mathcal{L}(B, \lambda)$$

- Contraintes :

$$\forall i \in [1, N], \sum_{j=1}^N a_{ij} = 1$$

$$\sum_{j=1}^N \pi_j = 1$$

- Critère intégrant les contraintes (Lagrangien) :

$$\mathcal{C}(\lambda) = \mathcal{L}(B, \lambda) - \sum_{i=1}^N \nu_i \left(\sum_{j=1}^N a_{ij} - 1 \right) - \eta \left(\sum_{j=1}^N \pi_j - 1 \right)$$

- Si la dérivée par rapport au coefficient de contrainte est nulle, la contrainte est satisfaite :

$$\frac{\partial \mathcal{C}(\lambda)}{\partial \eta} = 0 \Leftrightarrow \sum_{j=1}^N \pi_j - 1 = 0$$

- Ecriture du Maximum de Vraisemblance :

$$\begin{aligned} L(B, \lambda) &= \prod_{k=1}^K p(X^k | \lambda) = \prod_{k=1}^K \pi_{x_1^k} \prod_{t=2}^T a_{x_{t-1}^k, x_t^k} \\ L(B, \lambda) &= \prod_{i=1}^N \pi_i^{l_i} \prod_{j=1}^N a_{ij}^{n_{ij}} \end{aligned} \quad (1)$$

- n_{ij} # transitions (ij) observées, l_i # état initiaux i observés
- $\ell = \log(L(B, \lambda)) = \sum_{i=1}^N \left[l_i \log(\pi_i) + \sum_{j=1}^N n_{ij} \log(a_{ij}) \right]$
- Résolution : $\frac{\partial \ell}{\partial a_{ij}} = 0$, $\frac{\partial \ell}{\partial \pi_i} = 0$ + contraintes :

$$\pi_i = \frac{l_i}{K}, \quad a_{ij} = \frac{n_{ij}}{n_{i.}}, \quad \text{avec : } n_{i.} = \sum_j n_{ij}$$

- Approche par comptage
- Calcul des fréquences des évènements = solution au sens MV
- Chaque ligne de A est une distribution (sommant à 1)
- En faisant une hypothèse de stationnarité (ergodicité), il est possible d'estimer les π_j sur toute la base de données :

$$\text{classique : } \pi_j = \frac{l_j}{K} \quad \text{alternative stationnaire : } \pi_j = \frac{n \cdot j}{\sum_{ij} n_{ij}}$$