

Rapport de Projet : BirdCLEF+ 2026

Identification acoustique d'espèces dans le Pantanal sans réseaux de neurones

Yuxiang ZHANG / Ziyue ZHANG

19 mai 2026

Résumé

Ce rapport présente une solution de *machine learning* classique pour la compétition BirdCLEF+ 2026, dont l'objectif est d'identifier automatiquement 234 espèces animales à partir d'enregistrements audio continus collectés dans le Pantanal brésilien, sans utiliser de réseaux de neurones. Nous décrivons un pipeline complet qui combine une extraction de caractéristiques riches (descripteurs spectraux, MFCC avec dérivées temporelles, chroma, contraste spectral, enveloppe temporelle, *Bag of Audio Words* et factorisation NMF), une réduction de dimension par PCA et ANOVA, l'entraînement de trois familles de classifieurs (LightGBM, Random Forest, SVM avec noyau linéaire), une fusion pondérée, une classification hiérarchique par pseudo-ordres acoustiques, et un calibrage des probabilités (Platt / isotonique). Sur l'ensemble de validation interne, l'assemblage des trois modèles atteint un AUC ROC macro de **0,8060**, en nette progression par rapport à un modèle de référence simple (0,539 en score public). Les difficultés liées au calibrage et à l'introduction de la hiérarchie sont analysées en détail. L'ensemble du code respecte strictement l'interdiction des réseaux de neurones.

1 Introduction

La surveillance de la biodiversité dans les vastes zones reculées comme le Pantanal (plus de 150 000 km²) repose de plus en plus sur l'acoustique passive. Des centaines d'enregistreurs captent en continu les paysages sonores, produisant un volume de données impossible à analyser manuellement. La compétition BirdCLEF+ 2026 vise à développer des modèles d'apprentissage automatique capables d'identifier 234 espèces (oiseaux, amphibiens, insectes, mammifères) dans des segments de 5 secondes. La particularité du projet pédagogique est l'interdiction des réseaux de neurones. Nous avons donc élaboré une chaîne de traitement entièrement fondée sur des caractéristiques acoustiques *handcrafted*, des méthodes de dictionnaire, et des algorithmes d'ensemble classiques.

2 Exploration des données

2.1 Description du jeu de données

Le jeu d'entraînement comprend 35 549 enregistrements audio (fichiers `.ogg`) avec métadonnées (`train.csv`). Chaque échantillon possède une étiquette primaire (`primary_label`) et parfois des étiquettes secondaires (`secondary_labels`, 12,3% des cas). On dénombre 206 espèces dans l'étiquette primaire, mais le fichier de soumission requiert la prédiction de 234 classes : 28 espèces sont donc absentes de l'entraînement.

La distribution des classes est très déséquilibrée, comme le montre la Figure 1. L'espèce la plus représentée (`rubthr1`) compte 499 échantillons, tandis que 4 espèces n'en ont qu'un seul, et 18 en ont au plus 5. La médiane se situe à 125 échantillons. La classe *Aves* domine (97.9%),

suivie par *Amphibia*, *Insecta*, *Mammalia* et *Reptilia*. La note de qualité moyenne (**rating**) est de 2.6/5 (écart-type 2.07), reflétant des conditions d'enregistrement hétérogènes.




FIGURE 1 – Distribution du nombre d'enregistrements par espèce (Top 20 et Bottom 20).

2.2 Prétraitement audio

Tous les fichiers sont ré-échantillonnés à 32 000 Hz en mono. On extrait ensuite des segments de 5 secondes (la résolution temporelle de la compétition) : pour l'apprentissage, on prélève une fenêtre de 5 secondes au centre du fichier afin d'éviter les silences en bordure ; si le fichier est plus court, on le répète. Un spectrogramme de Mel (128 bandes, $n_{fft} = 2048$, $hop_length = 512$, $f_{min} = 20$ Hz, $f_{max} = 16\,000$ Hz) en échelle logarithmique (dB) est calculé pour chaque segment.

3 Ingénierie des caractéristiques

Afin de condenser l'information temps-fréquence en un vecteur de taille fixe, nous avons combiné des descripteurs globaux, des statistiques de segments, une représentation par *Bag of Audio Words* (BoAW) avec *bagging*, et une factorisation par NMF. L'ensemble produit un vecteur de dimension 2086 avant réduction.

3.1 Descripteurs *handcrafted* avancés

Le vecteur *handcrafted* (avant BoAW et NMF) totalise environ 1 126 dimensions et comprend les groupes suivants :

- Statistiques de Mel par segments** : le log-mel spectrogramme est découpé en 3 segments temporels égaux ; pour chaque segment on calcule moyenne et écart-type des 128 bandes. Cette opération (768 dimensions) capture l'évolution temporelle grossière.
- MFCC et dérivées temporelles** : 20 coefficients MFCC sont extraits, ainsi que leurs dérivées première (Δ) et seconde (Δ^2). Pour chacun de ces trois jeux, on calcule moyenne, écart-type, asymétrie (*skewness*) et aplatissement (*kurtosis*) le long du temps, soit $20 \times 4 \times 3 = 240$ dimensions.
- Chroma** (12 dimensions $\times$ 2 statistiques = 24) : distribution d'énergie sur les 12 classes de hauteur.
- Contraste spectral** (7 sous-bandes $\times$ 2 statistiques = 14) : différence pic-creux dans plusieurs bandes de fréquence, discriminant les vocalisations du bruit de fond.
- Rolloff spectral** (4 statistiques) : fréquence en dessous de laquelle se concentre 85% de l'énergie.

- f) **Bande passante spectrale** (4 statistiques).
- g) **Amplitude RMS** (4 statistiques) : intensité sonore instantanée en dB.
- h) **Taux de passage par zéro** (4 statistiques).
- i) **Enveloppe temporelle et modulation** (64 dimensions) : auto-corrélation de l'enveloppe RMS et spectre de modulation (FFT de l'enveloppe), qui capturent la périodicité et le rythme des vocalisations.

3.2 Bag of Audio Words avec *bagging*

Pour capter la structure locale des spectrogrammes, nous avons employé un modèle de *Bag of Audio Words*. Au lieu d'un unique dictionnaire, nous appliquons le principe du *bagging* : trois codebooks de $K = 256$ mots sont construits par clustering K-Means (MiniBatchKMeans) sur des échantillons bootstrap différents des trames Mel (vecteurs de 128 dimensions). Chaque segment audio est ensuite représenté par la concaténation des histogrammes normalisés des occurrences issues des trois codebooks, soit $3 \times 256 = 768$ dimensions. Cette approche réduit la variance de la quantification et améliore la robustesse.

3.3 Dictionnaire NMF

En complément de la quantification dure du BoAW, nous avons entraîné une factorisation par matrices non-négatives (NMF) avec 64 composantes sur les trames Mel (mises à l'échelle $[0,1]$). Chaque trame est représentée par un vecteur d'activations non-négatif, dont on agrège la moyenne, l'écart-type et le maximum le long du temps, fournissant un vecteur de $64 \times 3 = 192$ dimensions. La NMF permet une représentation *part-based* et douce des motifs spectraux, complémentaire au BoAW.

3.4 Concaténation et réduction de dimension

Les caractéristiques *handcrafted* (≈ 1126), le BoAW *bagging* (768) et la NMF (192) sont concaténés en un unique vecteur de dimension 2086. Après standardisation (**StandardScaler**), une PCA conserve les 350 premières composantes (81,5% de variance expliquée). Enfin, une sélection des 250 meilleures composantes par ANOVA (SelectKBest avec *f_classif*) est appliquée pour réduire le bruit et accélérer l'apprentissage.

4 Stratégie de modélisation

4.1 Approche multi-étiquette : *Binary Relevance*

Le problème étant multi-étiquette (plusieurs espèces pouvant co-occure), nous adoptons la stratégie *Binary Relevance* : pour chacune des 234 classes, un classifieur binaire indépendant est entraîné. Cette approche simple permet de gérer séparément le déséquilibre de chaque espèce et de paralléliser les calculs.

4.2 Classifieurs utilisés

Trois familles complémentaires ont été retenues :

- **LightGBM** (*gradient boosting*) : efficace, rapide, gère le déséquilibre via `scale_pos_weight`. Les hyperparamètres sont optimisés par Optuna (15 essais bayésiens sur une espèce représentative) : `num_leaves=82`, `learning_rate=0.024`, `feature_fraction=0.81`, `min_child_samples=32`, avec régularisations ℓ_1 et ℓ_2 . L'entraînement est limité à 300 itérations avec *early stopping* (30 rounds).

- **Random Forest** (*bagging*) : 100 arbres de profondeur maximale 12, avec `class_weight='balanced'`. Il produit des probabilités plus lisses et robustes.
- **SVM linéaire avec calibrage Platt** : un `LinearSVC` ($C = 0.5$, `class_weight='balanced'`) suivi d'un `CalibratedClassifierCV` (méthode sigmoïde) est entraîné uniquement pour les espèces ayant au moins 10 exemples positifs. Cela permet d'introduire la notion de noyau (linéaire) et d'obtenir des probabilités calibrées. Pour les espèces trop rares, aucun modèle SVM n'est appris (prédiction = 0).

4.3 Classification hiérarchique par pseudo-ordres acoustiques

La table taxonomique fournie ne contenant pas d'ordre biologique, nous avons construit une hiérarchie artificielle inspirée du cours (classification hiérarchique). Les espèces sont regroupées en 12 *pseudo-ordres* par K-Means appliqué aux vecteurs moyens des caractéristiques audio par espèce. Un classifieur multiclasse LightGBM prédit le pseudo-ordre d'un segment. Ensuite, pour chaque espèce, la probabilité finale est une interpolation entre la prédiction de l'espèce et la probabilité de son pseudo-ordre : $p_{\text{final}} = (1 - \alpha)p_{\text{espèce}} + \alpha p_{\text{ordre}}$, avec $\alpha = 0,15$. L'idée est que les espèces acoustiquement proches bénéficient d'un a priori commun.

4.4 Fusion d'ensemble

Les prédictions des trois modèles sont combinées par moyenne pondérée. Les poids optimaux sont cherchés par grid search sur le validation set, en maximisant l'AUC macro. Les poids retenus sont : $w_{\text{LGB}} = 0,20$, $w_{\text{RF}} = 0,10$, $w_{\text{SVM}} = 0,70$. La forte pondération du SVM s'explique par sa performance individuelle élevée et sa bonne calibration.

4.5 Calibrage des probabilités

Après fusion et application de l'a priori hiérarchique, un calibrage supplémentaire est effectué. Selon le nombre d'échantillons positifs de validation :

- $\geq 30 \rightarrow$ régresseur isotonique (non paramétrique, monotone) ;
- entre 10 et 29 $\rightarrow$ Platt scaling (régression logistique) ;
- $< 10 \rightarrow$ aucun calibrage.

5 Protocole expérimental

5.1 Division entraînement / validation

Les données sont partitionnées en 80% entraînement et 20% validation, avec stratification sur les étiquettes primaires. Les 4 espèces ne possédant qu'un seul échantillon sont placées intégralement dans l'entraînement. Aucune de ces espèces rares n'apparaît dans la validation.

5.2 Métrique d'évaluation

La compétition utilise l'**AUC ROC macro** calculée uniquement sur les classes ayant au moins un exemple positif dans le jeu de test. Nous reproduisons cette métrique : pour chaque espèce disposant d'au moins un positif en validation, l'AUC ROC est calculée, puis la moyenne est prise sur toutes ces classes.

5.3 Déroulement de l'entraînement

L'ensemble du pipeline est exécuté sur CPU (4 cœurs) sans accès Internet, pour une durée totale d'environ 10,8 heures. Les étapes principales sont détaillées en Annexe.

6 Résultats et analyse

6.1 Performances globales sur l'ensemble de validation

Les expériences ont été menées sur l'ensemble de validation interne (7 109 échantillons). La Figure 2 et le Tableau 1 synthétisent les AUC ROC macro obtenus pour chaque modèle et pour l'ensemble.

Modèle	AUC ROC macro
LightGBM seul	0,7486
Random Forest seul	0,7636
SVM (partiel)	0,7758
Ensemble (LGB+RF+SVM)	0,8060
Ensemble + calibrage	0,7502

TABLE 1 – AUC ROC macro sur l'ensemble de validation interne (7 109 clips).




FIGURE 2 – Comparaison des AUC macro des différents modèles sur la validation.

L'assemblage simple des trois classifieurs atteint **0,8060**, soit une amélioration de +0,03 par rapport au meilleur modèle individuel (SVM, 0,7758). La calibration diminue la performance à 0,7502, ce qui suggère qu'elle n'est pas bénéfique dans ce contexte (voir analyse détaillée plus bas).

6.2 Courbes ROC

La Figure 3 présente les courbes ROC des cinq espèces les plus fréquentes dans la validation. Les AUC sont compris entre 0,90 et 0,98, confirmant l'excellente discrimination pour les classes majoritaires.




FIGURE 3 – Courbes ROC des 5 espèces les plus représentées (ensemble sans calibrage).

6.3 Analyse du calibrage

La calibration a été appliquée de manière adaptative : 102 espèces ont bénéficié d’une calibration isotonique, 54 d’une calibration Platt, et 78 n’ont pas été calibrées (moins de 10 positifs en validation). La Figure 4 compare les courbes de fiabilité avant et après calibration pour les cinq espèces les plus fréquentes. On observe que les probabilités calibrées sont plus proches de la diagonale, indiquant une meilleure calibration individuelle. Cependant, l’AUC macro global chute de 0,8060 à 0,7502. Cette dégradation s’explique par le fait que les calibrateurs (surtout isotoniques) sont très sensibles au petit nombre de points de validation pour les espèces rares, introduisant une variance supplémentaire qui pénalise le score moyen.




FIGURE 4 – Courbes de calibration (fiabilité) avant et après calibration pour les 5 espèces les plus fréquentes.

6.4 Importance des caractéristiques

L’analyse de l’importance des caractéristiques (gain) a été menée sur un modèle LightGBM représentatif. La Figure 5 (gauche) montre les 30 caractéristiques individuelles les plus importantes, tandis que la Figure 6 (droite) agrège l’importance moyenne par groupe de caractéristiques. Les bandes SegMel dominent très largement (gain moyen $\approx 133\,000$), tandis que les autres groupes (MFCC, Chroma, BoAW, NMF, etc.) ont un gain moyen nul ou quasi nul. Cela suggère que pour cette espèce, les statistiques segmentées du spectrogramme Mel contiennent l’essentiel de

l'information discriminante, et que les caractéristiques supplémentaires n'ont pas été exploitées par l'arbre de décision (probablement en raison de la redondance ou de la régularisation).




FIGURE 5 – Top 30 des caractéristiques individuelles.




FIGURE 6 – Importance moyenne par groupe.

6.5 Étude d'ablation

Afin de quantifier l'apport de chaque groupe de caractéristiques, nous avons mené une étude d'ablation sur une espèce représentative (*chvcon1*, 116 échantillons d'entraînement). Le modèle LightGBM est ré-entraîné en supprimant tour à tour chaque groupe. Les résultats sont présentés dans la Figure 7. La suppression du groupe SegMel entraîne la chute la plus marquée (AUC de 0,861 à 0,816). Les autres groupes ont un impact très faible, confirmant la redondance observée lors de l'analyse des importances.




FIGURE 7 – Étude d'ablation sur l'espèce *chvcon1* : AUC obtenue en supprimant chaque groupe de caractéristiques.

Configuration	AUC
Toutes les caractéristiques	0,8609
Sans SegMel	0,8161
Sans BoAW (3x256)	0,8517
Sans NMF (3x64)	0,8498
Sans MFCC_deltas	0,8596
...	...

TABLE 2 – Valeurs d’AUC pour quelques ablations (extrait).

6.6 Impact de l’a priori hiérarchique

L’ajout de l’a priori basé sur les pseudo-ordres acoustiques fait chuter l’AUC macro de 0,8060 à 0,7312 (Figure 8). Cette forte dégradation s’explique par la mauvaise qualité des pseudo-ordres construits automatiquement. Le classifieur d’ordre, entraîné sur seulement 202 espèces avec des frontières floues, introduit un bruit qui pénalise la classification fine des espèces. Cette expérience souligne la difficulté d’intégrer une hiérarchie artificielle sans une taxonomie biologique fiable.




FIGURE 8 – Effet de l’a priori hiérarchique sur l’AUC macro.

6.7 Comparaison avec le modèle de référence

Une première soumission très simple (262 caractéristiques de base, uniquement LightGBM) a obtenu un score public de **0,539**. Notre pipeline actuel, même en retenant la version calibrée à 0,7502, représente une amélioration considérable. L’écart entre le score public et la validation s’explique par les 28 espèces absentes de l’entraînement (prédiction forcée à 0) et par les différences de distribution entre le sous-ensemble public et nos données.

7 Limites et perspectives

- **Redondance des caractéristiques** : l’analyse d’importance et l’étude d’ablation montrent que le groupe SegMel domine à lui seul la prédiction, tandis que les autres groupes sont largement inexploités. Une réduction de dimension plus agressive ou une sélection manuelle des groupes les plus discriminants pourrait simplifier le modèle et améliorer sa robustesse.
- **Calibrage** : la calibration isotonique, bien qu’efficace pour calibrer individuellement les probabilités, dégrade l’AUC macro global. Une stratégie prudente consisterait à ne l’appli-

quer qu’aux espèces ayant un nombre suffisant d’échantillons de validation, ou à utiliser une calibration basée sur la validation croisée pendant l’entraînement.

- **Hierarchie acoustique** : la construction des pseudo-ordres gagnerait à utiliser des métriques acoustiques plus adaptées (e.g., divergence de Bhattacharyya entre distributions de caractéristiques) ou à exploiter des données externes pour obtenir des regroupements phylogénétiques réels.
- **Espèces absentes de l’entraînement** : l’incorporation de vocalisations depuis Xeno-canto (autorisée par la compétition) comblerait en partie le déficit des 28 espèces inédites.
- **Temps d’exécution** : le pipeline complet prend plus de 10 heures, ce qui est trop long pour la soumission en l’état. La parallélisation de l’extraction des caractéristiques et une réduction du nombre de codebooks BoAW permettraient de respecter la limite de 9 heures.

8 Conclusion

Ce projet a abouti à un système d’identification acoustique multi-espèces entièrement fondé sur des méthodes traditionnelles. L’association de caractéristiques *handcrafted* avancées, de *Bagging of Audio Words*, de NMF, d’un assemblage de trois types de classifieurs (LightGBM, Random Forest, SVM) et d’une classification hiérarchique par pseudo-ordres illustre la richesse des techniques d’apprentissage automatique sans réseaux de neurones. L’assemblage simple atteint un AUC macro de validation de **0,8060**. Les analyses complémentaires (importance des caractéristiques, ablation, calibration, hiérarchie) ont permis de comprendre le rôle de chaque composant et d’identifier des pistes d’amélioration. Ce travail nous a permis de mettre en pratique l’ingénierie des caractéristiques audio, la réduction de dimension, les méthodes ensemblistes, le boosting, le bagging, les SVM, la calibration et les approches hiérarchiques, tout en respectant la contrainte pédagogique d’absence de réseaux de neurones.

Remerciements

Nous remercions l’équipe pédagogique pour ce projet stimulant et les organisateurs de Bird-CLEF+ pour la mise à disposition des données.

Annexe : structure du code final

Le code remis est organisé en plusieurs sections principales :

1. Imports et configuration globale (chemins, paramètres audio, constantes).
2. Création des pseudo-ordres par K-Means sur les centroïdes d’espèces.
3. Fonctions de chargement audio.
4. Extraction des caractéristiques *handcrafted* ($\sim 1\,126$ dim.) et du log-mel.
5. *Bagging* BoAW : construction de 3 codebooks et encodage.
6. Apprentissage du dictionnaire NMF (64 atomes) et extraction des activations.
7. Construction des étiquettes multi-hot et des étiquettes de pseudo-ordre.
8. Extraction complète des caractéristiques pour les 35 549 clips, avec cache.
9. Prétraitement : StandardScaler, PCA (350), SelectKBest (250).
10. Division entraînement / validation (stratifiée, gestion des espèces rares).
11. Optimisation des hyperparamètres LightGBM par Optuna (15 essais).
12. Entraînement du classifieur hiérarchique de pseudo-ordre.
13. Entraînement des 234 classifieurs LightGBM.

14. Entraînement des 234 classifieurs Random Forest.
 15. Entraînement des classifieurs SVM (uniquement si ≥ 10 positifs).
 16. Recherche des poids d'ensemble optimaux sur la validation.
 17. Application de l'a priori hiérarchique et calibrage (Platt / isotonique).
 18. Fonction d'inférence sur le jeu de test.
 19. Génération du fichier `submission.csv`.
 20. Sauvegarde de tous les artefacts (modèles, scaler, PCA, sélecteur, calibrateurs).
- L'intégralité du code respecte les contraintes de la compétition (CPU uniquement, pas d'accès Internet, pas de GPU).